CC2: Association entre le nombre de copies d'ADN mitochondrial et le risque de cancer de la prostate : Une analyse statistique.

UE : Statistiques et Analyses
de données du Vivant

ÉTUDIANTS : NADIM Tamime, PERDREAU Marie
DATE : 06/12/2025

Exercice 3 : Analyse de l'association entre le nombre de copies d'ADN mitochondrial et le risque de cancer de la prostate

Basé sur l'article de Zhou et al. (2014) , cet exercice vise à déterminer si le nombre de copies d'ADN mitochondrial (mtDNA) dans les leucocytes du sang périphérique est associé au risque de cancer de la prostate (PCa) et à la charge tumorale . Les données comparées proviennent d'un groupe de patients atteints de cancer et d'un groupe témoin sain.

Nous avons d'abord cherché à vérifier la normalité de la distribution de la variable d'intérêt `mtDNA copy number` au sein des deux groupes (Sains vs Malades) afin de choisir les tests de comparaison adéquats (paramétriques ou non paramétriques).Nous avons fait le test de normalité de Shapiro-Wilk.

```
> shapiro.test(dataSain$`mtDNA copy number`)

        Shapiro-Wilk normality test

data:  dataSain$`mtDNA copy number`
W = 0.94675, p-value = 1.299e-06

> shapiro.test(dataMalade$`mtDNA copy number`)

        Shapiro-Wilk normality test

data:  dataMalade$`mtDNA copy number`
W = 0.93592, p-value = 1.578e-07
```

Les tests de Shapiro-Wilk rejettent l'hypothèse de normalité pour les deux groupes avec des p-values très faibles ($p<0.05$).

La distribution n'étant pas gaussienne, nous utiliserons des tests non paramétriques pour la suite des comparaisons de moyennes et des corrélations.

Ensuite, nous avons comparé le nombre de copies de mtDNA entre les patients sains (Group 0) et les patients malades (Group 1).Via un test de Wilcoxon-Mann-Whitney (équivalent non paramétrique du test de Student).

```
> wilcox.test(data$`mtDNA copy number` ~ data$Group)

        Wilcoxon rank sum test with continuity correction

data:  data$`mtDNA copy number` by data$Group
W = 14667, p-value = 0.0002295
alternative hypothesis: true location shift is not equal to 0
```

Le test révèle une différence significative de position entre les deux groupes(p=0.00023). Donc on peut en déduire qu'il existe une différence significative du nombre de copies d'ADN mitochondrial entre les sujets sains et les sujets atteints d'un cancer de la prostate.

Enfin, afin de quantifier l'impact du nombre de copies de mtDNA sur la probabilité de développer un cancer, nous avons ajusté un modèle linéaire généralisé (GLM) de famille binomiale.

```
> ADNreg <- glm(Group ~ `mtDNA copy number`, family = "binomial", data = data)
> summary(ADNreg)

Call:
glm(formula = Group ~ `mtDNA copy number`, family = "binomial",
    data = data)

Coefficients:
                    Estimate Std. Error z value Pr(>|z|)
(Intercept)          -1.1845     0.3255  -3.639 0.000273 ***
`mtDNA copy number`   1.2674     0.3344   3.790 0.000151 ***
---
Signif. codes:  0 ‘***’ 0.001 ‘**’ 0.01 ‘*’ 0.05 ‘.’ 0.1 ‘ ’ 1

(Dispersion parameter for binomial family taken to be 1)

    Null deviance: 536.49  on 386  degrees of freedom
Residual deviance: 520.94  on 385  degrees of freedom
  (5 observations deleted due to missingness)
AIC: 524.94

Number of Fisher Scoring iterations: 4
```

Le coefficient associé au nombre de copies est positif (β1=1.267) et significatif (p=0.00015). L'intercept est de -1.18.

Le graphique (Figure 1 ci-dessous) illustre la courbe de probabilité prédite. On observe que la probabilité d'être dans le groupe "Cancer" augmente à mesure que le nombre de copies de mtDNA augmente.

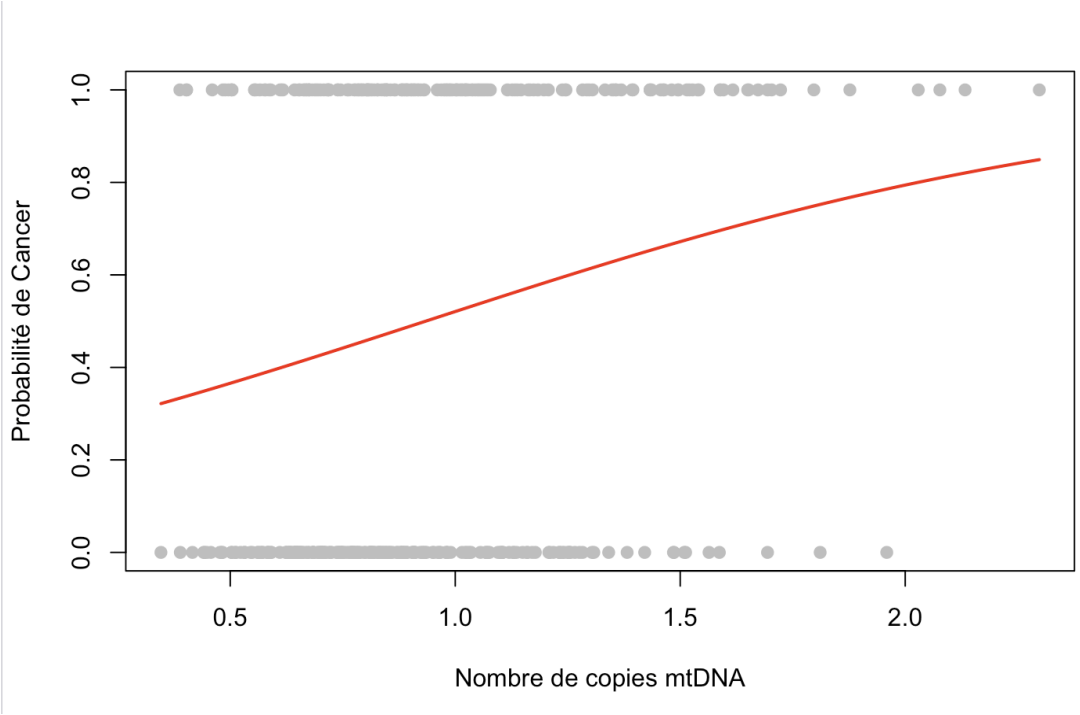

Conclusion :
On observe l'existence d'une association significative entre le taux d'ADN mitochondrial (mtDNA) leucocytaire et le cancer de la prostate. L'approche non paramétrique a d'abord mis en évidence une différence de distribution marquée entre les sujets sains et malades. Par la suite, la modélisation logistique a permis de caractériser cette relation : l'augmentation du nombre de copies de mtDNA est positivement corrélée à une élévation de la probabilité de cancer. Ces résultats suggèrent que le nombre de copies de mtDNA pourrait constituer un biomarqueur prédictif pertinent pour l'évaluation du risque de cancer de la prostate.

Annexe code utilise :

```
# Chargement des données
library(readxl)
data <- read_excel("mitochondries.xlsx", sheet = "Data Set")

# Création des sous-groupes
dataSain = subset(data, Group == "0")
dataMalade = subset(data, Group == "1")

# 1. Tests de Normalité (Shapiro-Wilk)
shapiro.test(dataSain$`mtDNA copy number`)
shapiro.test(dataMalade$`mtDNA copy number`)

# 2. Comparaison des groupes (Non paramétrique : Wilcoxon)
wilcox.test(data$`mtDNA copy number` ~ data$Group)

# 3. Régression Logistique (GLM Binomial)
ADNreg <- glm(Group ~ `mtDNA copy number`, family = "binomial", data = data)
summary(ADNreg)

# Graphique de la régression logistique
plot(data$`mtDNA copy number`, data$Group,
    xlab = "Nombre de copies mtDNA", ylab = "Probabilité de Cancer",
    pch = 19, col = "gray")
curve(predict(ADNreg,
            newdata = data.frame(`mtDNA copy number` = x, check.names = FALSE),
            type = "response"),
     add = TRUE, col = "red", lwd = 2)

# 4. Corrélations de Spearman (PSA et Gleason)
cor.test(dataMalade$`mtDNA copy number`, dataMalade$`PSA level (ng/ml)`, method =
"spearman")
cor.test(dataMalade$`mtDNA copy number`, dataMalade$`Gleason score`, method =
"spearman")

# 5. Comparaison selon le stade TNM (Kruskal-Wallis)
dataMalade$`TNM stage` <- as.factor(dataMalade$`TNM stage`)
kruskal.test(`mtDNA copy number` ~ `TNM stage`, data = dataMalade)
```

Exercices

EXERCICE 7:

Nous avons effectué ces exercices à l'aide de R, vous trouverez ici le code ainsi que les réponses du logiciel.

Question 1 - Code

```
# Création des jeux de données
longueur_corporelle <- c(243, 280, 305, 310, 320, 320, 333, 336, 349, 375, 400, 409, 426, 428, 431, 435, 435, 435, 436, 440, 440, 443)

longueur_queue <- c(60, 66, 78, 76, 72, 78, 82, 81, 86, 85, 100, 90, 88, 100, 105, 107, 106, 109, 103, 111, 102, 110)

longueur_corne <- c(4.5, 3.0, 5.0, 36.0, 42.0, 50.0, 50.0, 64.0, 44.0, 77.0, 112.0, 105.0, 113.0, 145.0, 150.0, 167.0, 147.0, 126.0, 129.0, 162.0, 127.0, 159.0)

masse_corporelle <- c(210, 409, 528, 498, 508, 214, 630, 700, 620, 792, 870, 900, 900, 970, 1150, 1539, 1458, 1000, 1150, 1620, 1000, 1629)

mean(longueur_corporelle)
median(longueur_corporelle)
sd(longueur_corporelle)
summary(longueur_corporelle)

mean(longueur_queue)
median(longueur_queue)
sd(longueur_queue)
summary(longueur_queue)

mean(longueur_corne)
median(longueur_corne)
sd(longueur_corne)
summary(longueur_corne)

mean(masse_corporelle)
median(masse_corporelle)
sd(masse_corporelle)
summary(masse_corporelle)
```

Question 1 - Réponse

```
# Création des jeux de données
> longueur_corporelle <- c(243, 280, 305, 310, 320, 320, 333, 336, 349,
375, 400, 409, 426, 428, 431, 435, 435, 435, 436, 440, 440, 443)
> longueur_queue <- c(60, 66, 78, 76, 72, 78, 82, 81, 86, 85, 100, 90,
88, 100, 105, 107, 106, 109, 103, 111, 102, 110)
> longueur_corne <- c(4.5, 3.0, 5.0, 36.0, 42.0, 50.0, 50.0, 64.0,
44.0, 77.0, 112.0, 105.0, 113.0, 145.0, 150.0, 167.0, 147.0, 126.0,
129.0, 162.0, 127.0, 159.0)
> masse_corporelle <- c(210, 409, 528, 498, 508, 214, 630, 700, 620,
792, 870, 900, 900, 970, 1150, 1539, 1458, 1000, 1150, 1620, 1000,
1629)
> # Question 1
> mean(longueur_corporelle)
[1] 378.5909
```

```
> median(longueur_corporelle)
[1] 404.5
> sd(longueur_corporelle)
[1] 62.95248
> summary(longueur_corporelle)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  243.0   323.2   404.5   378.6   435.0   443.0
> mean(longueur_queue)
[1] 90.68182
> median(longueur_queue)
[1] 89
> sd(longueur_queue)
[1] 15.35109
> summary(longueur_queue)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  60.00   78.75   89.00   90.68  104.50  111.00
> mean(longueur_corne)
[1] 91.70455
> median(longueur_corne)
[1] 108.5
> sd(longueur_corne)
[1] 55.46055
> summary(longueur_corne)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
    3.0    45.5   108.5    91.7   141.0   167.0
> mean(masse_corporelle)
[1] 877.0455
> median(masse_corporelle)
[1] 885
> sd(masse_corporelle)
[1] 422.7533
> summary(masse_corporelle)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
    210     551     885     877    1112    1629
```

Question 2

code:

boxplot(longueur_corporelle,main = "longueur_corporelle", ylab = "Longueur (cm)")
boxplot(longueur_queue,main = "longueur_queue", ylab = "Longueur (cm)")
boxplot(longueur_corne,main = "longueur_corne", ylab = "Longueur (cm)")
boxplot(masse_corporelle,main = "masse_corporelle", ylab = "Longueur (cm)")

résultat:

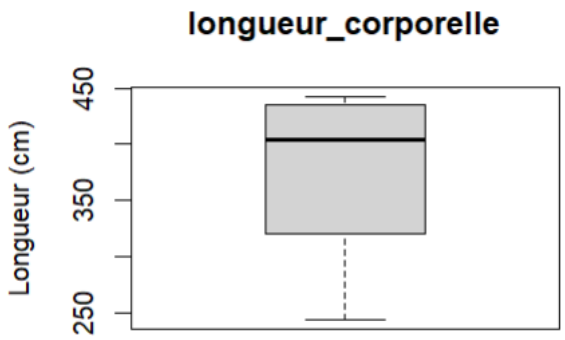

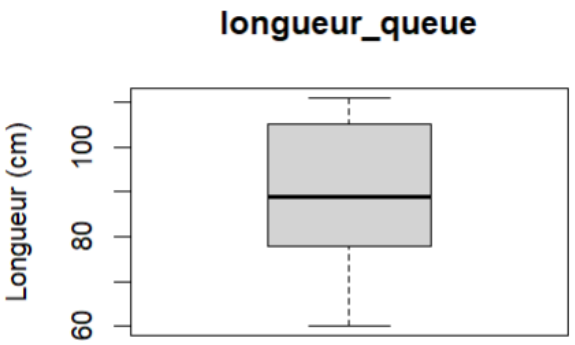

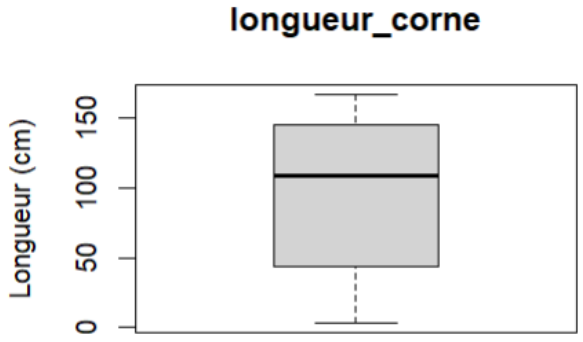

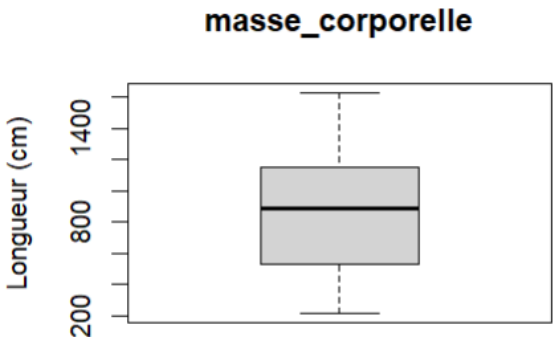

Question 3:

	0.95	0.99
t.test(longueur_corporelle, conf.level = 0.95) (ou 0.99)	350.6793 406.5025	340.5898 416.5920
t.test(longueur_queue, conf.level = 0.95) (ou 0.99)	83.87553 97.48811	81.41517 99.94847
t.test(longueur_corne, conf.level = 0.95) (ou 0.99)	67.11471 116.29438	58.2259 125.1832
t.test(masse_corporelle, conf.level = 0.95) (ou 0.99)	689.6072 1064.4838	621.8513 1132.2396

Question 4:
Nous traçons les régressions linéaires des données
code:

lm(longueur_corne ~ longueur_corporelle)
summary(lm(longueur_corne ~ longueur_corporelle))
plot(longueur_corporelle,longueur_corne)
abline (lm(longueur_corne ~ longueur_corporelle))

résultat:

```
Call:
lm(formula = longueur_corne ~ longueur_corporelle)

Residuals:
    Min      1Q  Median      3Q     Max 
-24.391 -12.256   1.038  10.683  27.609 

Coefficients:
                      Estimate Std. Error t value Pr(>|t|)    
(Intercept)         -228.87184   20.85682  -10.97 6.49e-10 ***
longueur_corporelle    0.84676    0.05438   15.57 1.20e-12 ***
---
```

```
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 15.69 on 20 degrees of freedom
Multiple R-squared:  0.9238, Adjusted R-squared:   0.92
F-statistic: 242.5 on 1 and 20 DF,  p-value: 1.205e-12
```

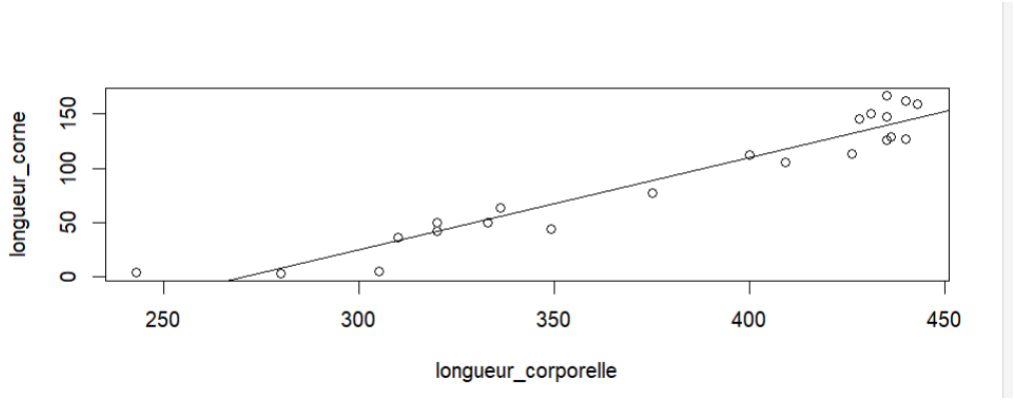

lm(masse_corporelle ~ longueur_corne)
summary(lm(masse_corporelle ~ longueur_corne))
plot(masse_corporelle,longueur_corne)
abline (lm(longueur_corne ~ masse_corporelle))

```
summary(lm(masse_corporelle ~ longueur_corne))
Call:
lm(formula = masse_corporelle ~ longueur_corne)
Residuals:
   Min     1Q Median     3Q    Max
-372.0 -121.7   11.2  121.3  282.3
Coefficients:
               Estimate Std. Error t value Pr(>|t|)
(Intercept)    236.9912    72.9859   3.247  0.00404 **
longueur_corne   6.9795     0.6852  10.186 2.32e-09 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 174.1 on 20 degrees of freedom
Multiple R-squared:  0.8384,   Adjusted R-squared:  0.8303
F-statistic: 103.8 on 1 and 20 DF,  p-value: 2.319e-09
```

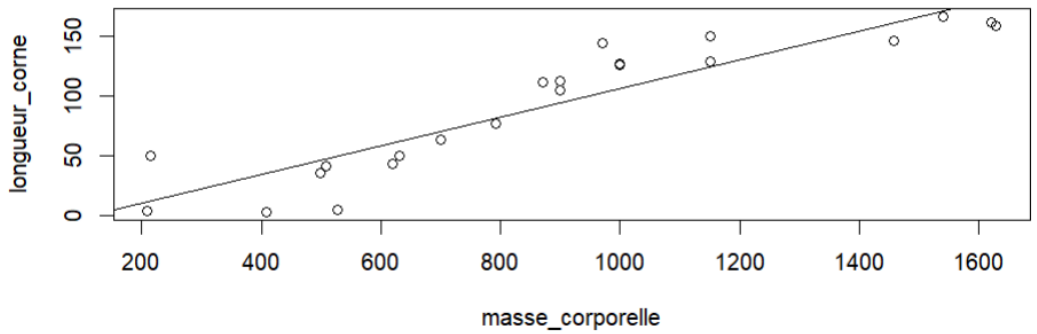

On observe que la longueur de la corne semble liée à la longueur corporelle, car la régression linéaire donne un R^2 de 0.92, et un peu moins liée à la masse corporelle car le R^2 est plus faible,seulemet 0.83.

EXERCICE 8:

code

```
saines <- c(52.81, 52.90, 43.57, 50.92, 49.11, 61.24, 50.91, 60.30, 46.79, 52.95, 61.14,
50.15, 49.03, 57.50, 53.42, 43.86, 45.32, 50.36, 35.88, 43.90)
malades <- c(69.66, 73.83, 69.51, 40.43, 62.31, 52.87, 43.08, 59.22, 66.65, 51.53, 62.80,
58.31, 39.17, 53.08, 45.62, 78.04, 53.65, 63.91, 72.72, 57.57)
#install.packages("pROC") (n'était pas installé sur cet ordinateur, mais passé en
commentaire pour re faire tourner le script)
library(pROC)

valeurs <- c(saines, malades)
etat <- c(rep(0, length(saines)), rep(1, length(malades)))
data <- data.frame(valeurs, etat)

roc <- roc(data$etat, data$valeurs, levels=c(0,1),direction ="<")

seuil <- coords(roc, "best", ret=c("seuil", "specificity", "sensitivity"))

print(seuil)

plot(roc, print.thres = "best", main = "courbe ROC")
```

Courbe résultat:

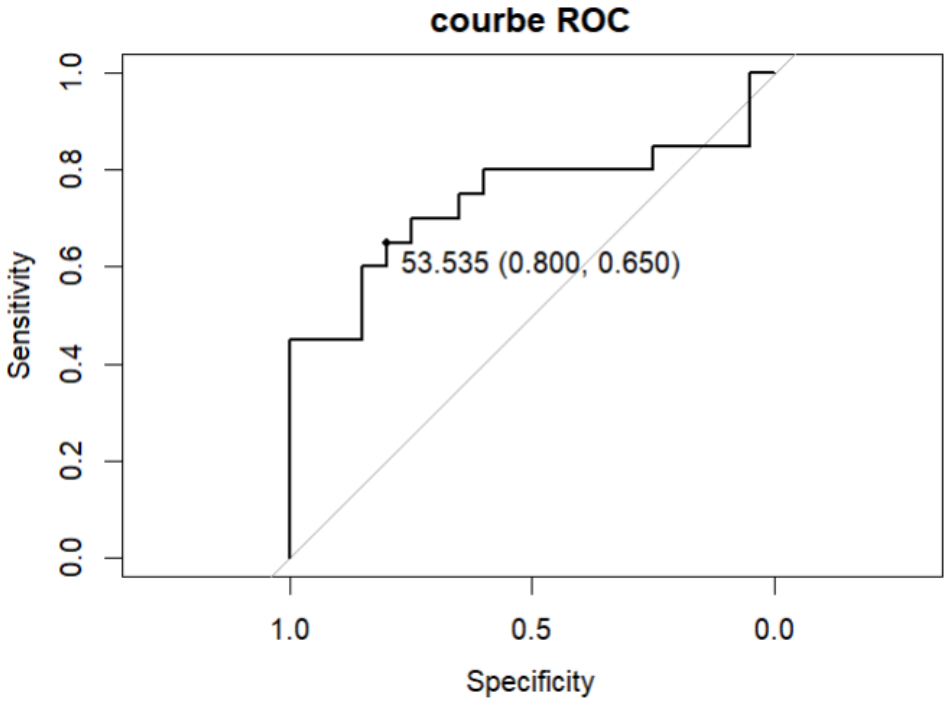

Le meilleur seuil est donné par le point dont les coordonnées sont affichées, c'est donc 53.535

EXERCICE 9:

Question 1 :

formules:

$x_{moyenne}$ = Somme(x_i)/n

écart-type corrigé = Racine [Somme(x_i - $x_{moyenne}$)/(n-1)]

code:

albumine <- c(39.92, 51.06, 48.40, 33.98, 49.84, 37.98, 27.49, 34.22, 51.19, 52.48, 36.15, 54.12, 38.00, 32.10, 48.83, 43.23, 44.61, 50.81, 41.69, 46.68)

mean (albumine)

sd(albumine)

résultats:

```
> albumine <- c(39.92, 51.06, 48.40, 33.98, 49.84, 37.98, 27.49, 34.22,
51.19, 52.48, 36.15, 54.12, 38.00, 32.10, 48.83, 43.23, 44.61, 50.81, 41.69,
46.68)
> mean (albumine)
[1] 43.139
> sd(albumine)
[1] 7.808364
```

Question 2 :

Pour la médiane et les quartiles de la série on utilise la commande *summary(albumine)*

On obtient:

```
> summary(albumine)
   Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
  27.49   37.52   43.92   43.14   50.08   54.12
```

Donc le 1er quartile est 37.52, la médiane est 43.92 et le 3eme quartile est 50.08

Question 3 :

On calcule le degré de liberté de la série: ddl = n - 1 = 20 - 1 = 19

Pour 5% de taux d'erreur, on a alpha = 2.5% soit 0.025

Ainsi dans notre code on doit mettre: qt(0.975, df=19) ce qui nous donne pour résultat :

```
2.093024
```

A la main, on aurait cherché cette valeur dans la table de Student en utilisant le degré de liberté et 1-alpha.

Question 4 :

Pour avoir l'IC, on ait sur R: *t.test(albumine)* . On obtient ainsi pour résultat:

```
t = 24.707, df = 19, p-value = 6.621e-16
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 39.48457 46.79343
```

Question 5 :

Le test utilisé dans l'énoncé est celui de Student. La phrase "true mean is not equal to 45" signifie que la condition testée est que la moyenne soit de 45. On a donc les hypothèses:

H0 : dans une population homogène de personnes en bonne santé dans une catégorie d'âge 25-50 ans, le nombre de grammes d'albumine par litre de sang de ces personnes est de 45

H1: dans une population homogène de personnes en bonne santé dans une catégorie d'âge 25-50 ans, le nombre de grammes d'albumine par litre de sang de ces personnes est différent de 45

45 est dans l'IC, et de plus la p-value donnée (0.2998) est bien supérieure à 0.05, alors on ne rejette pas H0.

Ainsi on peut dire que le taux d'albumine dans une population homogène de personnes en bonne santé dans une catégorie d'âge 25-50 ans soit différent de 45.

EXERCICE 10:

Question 1:

code:

```
domicile <- c(35.6, 32.8, 38.3, 43.9, 41.8, 41.1, 46.0, 37.9, 31.8, 35.1, 46.6, 40.9, 34.5, 34.3, 38.3)
ehpad <- c(37.2, 26.1, 35.2, 35.5, 32.1, 18.3, 23.1, 35.1, 42.1, 22.4, 40.1, 29.0, 26.2, 29.9, 23.5)

mean(domicile)
sd(domicile)
mean(ehpad)
sd(ehpad)

t.test(domicile)
t.test(ehpad)
```

résultat:

```
domicile <- c(35.6, 32.8, 38.3, 43.9, 41.8, 41.1, 46.0, 37.9, 31.8, 35.1,
46.6, 40.9, 34.5, 34.3, 38.3)
> ehpad <- c(37.2, 26.1, 35.2, 35.5, 32.1, 18.3, 23.1, 35.1, 42.1, 22.4,
40.1, 29.0, 26.2, 29.9, 23.5)
> t.test(domicile)
      One Sample t-test

data:  domicile
t = 31.986, df = 14, p-value = 1.722e-14
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
 36.00546 41.18121
sample estimates:
mean of x
 38.59333

> t.test(ehpad)

      One Sample t-test

data:  ehpad
t = 16.633, df = 14, p-value = 1.288e-10
alternative hypothesis: true mean is not equal to 0
95 percent confidence interval:
```

```
 26.46833 34.30500
sample estimates:
mean of x
 30.38667
```

On peut en conclure que pour la condition domicile, la moyenne est de 38.5933 et que l'intervalle de confiance va de 36.00546 à 41.18121
et pour la condition ehpad, la moyenne est de 30.38667 et l'intervalle de confiance va de 26.46833 à 34.30500

Question 2:

Le test de Shapiro - Wilk a pour H0: la distribution suit une loi normale, ainsi trouver des p-value de 0.5359 et 0.8076 (largement supérieures à 0.05) nous indique qu'on ne peut rejeter H0 et donc que la distribution pourrait suivre une loi normale.
Le test de Bartlett a pour H0: les variances des 2 séries de données sont égales. On trouve une p-value de 0.1326, largement supérieure à 0.05 donc on ne peut rejeter H0 et donc les 2 séries de données pourraient avoir la même variance.
Sur des séries de distribution normales, on peut appliquer le test de Student.

Question 3:
Le test de Bartlett a montré qu'on peut considérer les variances égales.
Le 1er test proposé, celui de Welch, suppose que les variances ne sont pas égales, on utilisera donc les résultats du 2eme test proposé dans la consigne.
En utilisant les données, on effectue :
en suivant la formule:

$t = (x_{moyenne,\ 1} - x_{moyenne,\ 2}) / (s*(1/n1 - 1/n2)$

```
ou sur R:
> t.test(ehpad, domicile, var.equal = TRUE)

      Two Sample t-test

data:  ehpad and domicile
t = -3.7484, df = 28, p-value = 0.0008216
alternative hypothesis: true difference in means is not equal to 0
95 percent confidence interval:
 -12.69144  -3.72189
sample estimates:
mean of x mean of y
 30.38667  38.59333
```

La p-value est très faible, on peut rejeter H0: la moyenne des 2 groupes est identique. On peut donc conclure sur H1: le groupe domicile a une moyenne plus élevée que le groupe ehpad.

Question 4:
Le test de Wilcoxon compare la distribution des valeurs de 2 séries de données. Avec H0: les 2 séries suivent la même distribution, et une p-value très faible, on peut rejeter H0 et accepter H1: les 2 séries de données ne suivent pas la même distribution, l'une est globalement plus élevée que l'autre.